

# 가속도센서를 활용한 회귀모델의 유량 예측

## A Flow Rate Prediction of Regression Models Using an Acceleration Sensor

최윤규<sup>1</sup> · 이명기<sup>2</sup> · 김성민<sup>3</sup>

Yungyu Choi and Myeonggi Lee and Seongmin Kim

<sup>1</sup>인공지능사관학교 사물지능반

E-mail: sw22tmango@gmail.com

<sup>2</sup>인공지능사관학교 사물지능반

E-mail: lmk7579@naver.com

<sup>3</sup>인공지능사관학교 사물지능반

E-mail: to4tjdals@naver.com

### 요 약

본 논문은 물병으로 섭취한 수분의 양을 측정하는 방법에 대한 것으로, 물병에 부착된 가속도 센서가 측정한 데이터를 이용하여 물병으로부터 흘러나온 유량을 측정하는 회귀분석을 시도하고 제안한 방법의 실효성과 한계에 대해 검토한다.

**키워드** : 머신러닝, 딥러닝, 회귀분석, 가속도센서(MPU6050)

## 1. 서 론

센서를 이용해서 물병으로부터 빠져나간 물의 양을 측정하는 방법에는 여러가지가 있다. 접촉식/비접촉식 수위 센서 또는 초음파 센서를 이용해서 사전수위와 사후수위를 측정하고 비교하는 방법, 무게센서나 압력센서를 이용하여 사전무게와 사후무게를 측정하고 그것들의 무게차를 이용하여 측정하는 방법 등이 그것이다.

본 논문에서는 가속도센서를 활용한 방법을 제안한다. 가속도센서는 센서값으로 각가속도를 측정해주는데 이를 적분하면 각속도를 얻을 수 있고 이를 다시 적분하면 각도를 얻을 수 있다. 본 연구에 사용된 모델들은 이렇게 얻은 각도를 feature data로, 물병으로부터 빠져나간 물의 양을 label data로 설정하고 회귀분석을 시도한다. 가속도센서에서 얻을 수 있는 값 이외에도 물병에 담긴 물의 수위, 물이 흐르는 시간 등의 다양한 변수들이 존재하고 유체역학 등을 활용한 공학적인 방법을 사용하여 값을 추정할수도 있을 것이다. 하지만 본 논문은 이러한 수학적 접근보다 machine learning과 deep learning을 활용한 회귀분석이 이러한 문제에 얼마나 잘 대답할 수 있는지에 관심이 있다.

## 2. 가속도센서

실험에 사용한 가속도센서는 MPU6050이다. 가속도센서란 총 6축 센서로 힘의 가속도 3축(x축, y축, z축)방향과 3차원 축 회전 방향의 각속도 그리고 온도를 측정한다. 그리고 측정한 값들로부터 센서가 3차원 축 회전 방향으로 얼마나 기울었는지를 파악할 수 있다. 하지만 MPU6050센서는 몇가지 이유 때문에 측정한 값들을 바로 활용할 수 없다.

첫째, 각속도를 적분해서 얻은 값 thetaX, thetaY, thetaZ를 신뢰하기 어렵다. 각속도계만으로 각도를 계산

하면 적분 오차가 누적되어 수평상태에 있음에도 각도가 밀려나는 드리프트 현상이 발생할 수 있기 때문이다.[1]

둘째, 가속도계는 외부 진동이나 환경에 민감하게 반응해서 급격하게 센서의 위치가 변하는 경우, thetaX, thetaY에 큰 오차가 발생한다. 이는 센서가 자신에게 가해지는 힘의 방향을 기준으로 자신이 얼마나 기울었는지를 파악하기 때문이다.

이러한 문제점들을 해결하고 정확한 각도를 계산하기 위해 널리 사용 되는 방법에는 칼만필터와 상보필터가 있다.[2] 상보필터는 저대역은 가속도계 값을, 고대역은 각속도계 값을 가져와 서로 합치는 것이다. 가속도계 값은 오차누적은 없지만 고주파 잡음이 있고 자이로계는 단기간엔 정확하지만 저주파 잡음이 있다. 상보필터는 두 센서의 값들을 합쳐 단점을 보완한다. 본 논문에서는 0.1초 단위의 빠른 계산이 필요했기 때문에 비교적 정확하고 느린 칼만필터보다 정확성은 조금 떨어지지만 계산이 빠른 상보필터를 사용한다.

$$\theta = (1 - \alpha) \times \theta_{accel} + \alpha \times \theta_{gyro}$$

[2]

## 3. 회귀분석

### 3.1 데이터 수집 및 전처리

회귀분석을 위해 사용할 데이터는 직접 수집하였다. feature data는 물병에 가속도센서를 부착하고 물을 마시는 동안 각도를 0.1초 단위로 3초동안 측정하여 시간 변수를 통제하였다. 측정된 각도는 무선통신으로 데이터베이스에 저장하였다. label data는 물 마시기 전 무게센서를 통해 측정한 물병의 무게와 물을 마신 후 측정한 값

의 차로 물병으로부터 빠져나간 물의 양을 계산했다. 1000건의 데이터를 수집하였고 이상치 데이터를 제거했다. 이상치가 제거된 985건의 데이터를 sklearn의 train\_test\_split 함수로 0.8 : 0.2로 나누어 학습을 진행하였다.

feature data의 각 칼럼이 시간의 연속선상에서 수집된 값이므로 상호간의 상관관계수가 높아 발생하는 다중공선성으로 인한 overfitting이 우려되었다. 따라서 machine learning의 경우 0.1초씩 3초동안 모은 30개의 feature data에서 요약통계로 mean, std, 25%, 50%, 75%, max 6개의 feature를 추출해 학습을 진행하였다. deep learning의 경우에는 기존 30개의 feature data를 그대로 사용하여 학습을 진행하였다.

### 3.2 Gradient Boost Model(GBM)

machine learning에 사용한 모델은 GBM이다. GBM이 machine learning algorithm 중 예측성능이 가장 높다고 알려진 algorithm이기 때문이다.

학습 결과 train과 test의 RMSE(Root Mean Square Error)는 9.23ml와 12.81ml였다. train data와 test data의 오차가 10ml 안팎이기 때문에 근사치로 예측한 것 처럼 보이지만 score메소드를 활용하여 R2(R-Squared Score)를 계산하면 각각 0.53, 0.11로 underfitting되어 있음을 알 수 있다.

데이터셋의 부족으로 underfitting이 야기되었을 가능성이 있어 GridSearchCV를 사용하여 hyperparameter tuning과 cross validation을 진행하였지만 Best Test Score는 0.15로 0.04 상승하는데 그쳤다.

### 3.2 Mulit-Layer Perceptron(MLP)

deep learning에 사용한 모델은 MLP이다. 앞선 machine learning학습에서 underfitting하는 모습을 보였기 때문에 model-1은 은닉층을 두텁게 쌓아서 학습을 진행하였다. model-1의 RMSE는 train data의 경우 1.08ml로 매우 낮은 오차를 보인 반면 test data는 15.66ml로 다소 높았다. model-1이 overfitting을 보였으므로 model-2는 은닉층을 조금 더 얇게 구성하고 dropout을 추가하여 overfitting을 방지하고 학습을 진행하였다.

model-2의 RMSE는 아래 그래프와 같이 학습이 진행되다가 train data와 test data 각각 6.30ml, 15.66ml 정도에서 더 이상 학습이 진행되지 않았다.

## 4. 결론

본 논문에서 실시한 연구 결과에 따르면 model-1에서는 overfitting이 GBM과 model-2에서는 underfitting 현상이 나타났다. 데이터 셋의 부족을 감안하더라도 오차가 높게 나타났다. 따라서 GBM과 MLP 모두 시간에 따른 가속도센서의 값만으로는 유량을 예측하기 어려운 것으로 보인다. 물병에 담겨있는 물의 수위와 같은 변수들이 통제되지 않았고 feature data에도 반영되지 못한 것이 그 원인이라 생각된다.

## 감사의 글

본 연구는 2022년 광주인공지능사관학교 교육운영 사업 교육지원비 학술논문 발표 지원으로 이루어졌습니다.

## 참 고 문 헌

- [1] "MPU6050", NAVER blog, 2022-5-15, <https://m.blog.naver.com/PostView.naver?blogId=intheglass14&logNo=222733146796>
- [2] "MPU6050 (5) - (확장)칼만필터 적용", NAVER blog, 2022-7-7, <https://m.blog.naver.com/intheglass14/222803522635>

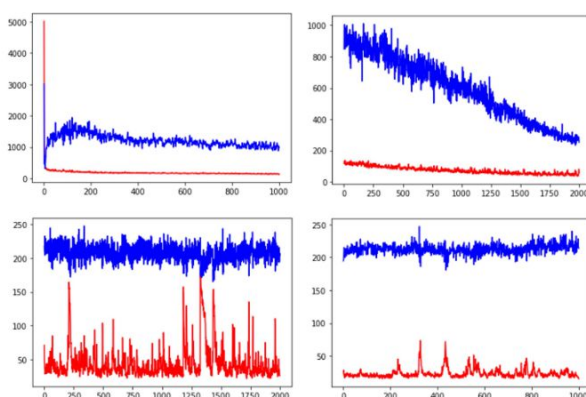


그림1. MLP의 MSE의 변화  
Fig. 1. Changes of MSE in Model-2